




ЭКСКУРСИЯ ПО КРЫШАМ ПЕТЕРБУРГА ОТ CASE CRUSHERS

Экскурсоводы:

Арина Базукина

Вероника Дмитренко


Даниил Симонов

Илья Колосов

Руслан Темерханов

[План экскурсии](#) (GitHub репозиторий)

[Брошюра с видом на Питер](#) (3D визуализация)



Executive Summary

Сопоставление

- 01** Подсчет силы связи между полигонами с пересечением
- 02** Составление графа и объединение пар с наибольшей силой
- 03** Приоритизация компоненты А и компоненты Б

Модель

- 01** Категориальные признаки вносят наибольший вклад - 60% влияния на предсказание высоты
- 02** Random Forest и CatBoost предсказывают высоту зданий с ошибкой менее одного этажа у большинства объектов

Выводы

- 01** Высота восстановлена для всех зданий города
- 02** Кластеризация разбила застройку на типы среды - каждый получил готовую стратегию для планирования сети

КЛЮЧЕВОЙ РИСК - НЕСОГЛАСОВАННЫЕ И АНОМАЛЬНЫЕ ВЫСОТНЫЕ АТТРИБУТЫ

Проблемы

- 01 Нерелевантные объекты
- 02 Аномальные площади
- 03 Ошибки этажности
- 04 Несогласованность высотных признаков
- 05 Разнородная семантика объектов

Этапы очистки



КЛЮЧ К ПРИОРИТИЗАЦИИ ДАННЫХ ИЗ А И В - ТИП ПРОСТРАНСТВЕННОГО СООТВЕТСТВИЯ ОБЪЕКТОВ

Хорошие совпадения

Один и тот же дом в обоих источниках

Контуры почти совпадают




Параллельный сдвиг

Форма совпадает, но один контур смещен

Решение

Применять корректирующий сдвиг к слоям



Один в другом

Один источник описывает весь дом, другой - лишь его часть

Решение

В качестве основного геометрического объекта используем больший контур




Совсем другой дом

Объекты пространственно близки, но относятся к разным зданиям

Решение

Добавлять оба строения как отдельные объекты




Пограничные и нестандартные случаи


Метрики противоречат друг другу, класс определить нельзя

Решение


Исключаем из обучения и автослияния



ДЛЯ КАЖДОЙ ПАРЫ ПОЛИГОНОВ С ПЕРЕСЕЧЕНИЕМ СЧИТАЕМ СИЛУ ИХ СВЯЗИ



ОБЪЕДИНЯЕМ ТОЛЬКО ПАРЫ С **ВЫСОКИМ** УРОВНЕМ СВЯЗИ. У КАЖДОГО ПОЛИГОНА ОСТАЕТСЯ **ТОЛЬКО 2 ЛУЧШИЕ** СВЯЗИ



ПОЛУЧЕННЫЕ КОМПОНЕНТЫ А И В ПРИОРИТИЗИРУЮТСЯ ПО СЛЕДУЮЩЕЙ МЕТРИКЕ

SOURCE_SCORE



$score_A > score_B + margin$ значит берем A

ЛУЧШИЙ РЕЗУЛЬТАТ ПОКАЗАЛ CATBOOST СРЕДИ ДВУХ МОДЕЛЕЙ, ГДЕ ГЛАВНЫМИ ПРИЗНАКАМИ ВЫДЕЛЕНА КАТЕГОРИЯ ЗДАНИЙ

В литературе и промышленных решениях выделяются три класса методов предсказания высоты зданий:

Класс метода	Данные/источники	Точность (MAE)
Эвристика и правила По числу этажей, нормам застройки, тени	Кадастр, административные данные, спутник	5–10 м (грубая оценка)
Классический ML Random Forest, Gradient Boosting, SVR	Геометрия footprint, соседи, категориальные признаки	2–4 м (хорошая)
Глубокое обучение CNN на аэрофото, graph neural networks	Aerial/satellite images, LiDAR	1–3 м (отличная, но требует снимков)

с учетом всех ограничений самый оптимальный подход - классический ML

Всего сконструировано около 47 признаков в трех группах:

Геометрические

Описывают форму и размер контура здания

13 штук

Пространственные

Характеристики окружения здания


17 штук

Категориальные

Назначение здания, этажность и метаданные из обоих источников

17 штук

В обучении использовались только самые релевантные признаки



Модель 1

Random Forest

Деревьев 400 баланс качества и скорости

Признаков в узле $\sqrt{p} \approx 6$ снижает корреляцию деревьев

Минимум объектов в листе 5

Цель обучения $\log(1 + \text{высота})$ нормирует скошенное распределение

Аугментация высоких зданий >50 м

Модель 2

CatBoost

Итераций (макс) 2000с ранней остановкой

Шаг обучения 0.03 малый → меньше переобучения

Глубина дерева 8 улавливает сложные зависимости

Ранняя остановка 150 раундовнет улучшения → стоп

Цель RMSE (м) оптимизируется напрямую

Обычное случайное разбиение завышает метрики: соседние здания похожи и “подсказывают” ответ - это пространственная автокорреляция. Пространственная CV исключает этот эффект.

RF - K-Means 5 зон

Город → 5 кластеров по координатам. Каждый по очереди - тестовый. Зоны территориально разделены

CatBoost - GroupKFold по районам

5 фолдов по районам города. Один район тестовый, остальные - обучение. Ранняя остановка по каждому фолду.

MAE

Средняя абсолютная ошибка

1.244	Random Forest
0.451	CatBoost

RMSE

Корень среднеквадратичной ошибки

3.265	Random Forest
2.565	CatBoost

R²

Доля объясненной вариации высот

0.949	Random Forest
0.970	CatBoost

ПОЛУЧЕННАЯ ВИЗУАЛИЗАЦИЯ ПРЕДСКАЗАННЫХ ВЫСОТНОСТЕЙ СОГЛАСУЕТСЯ С РЕАЛЬНОСТЬЮ



Сегментация районов по типовым сценариям позволяет перейти к **адресному радиопланированию**




CASE CRUSHERS



Арина Базукина
НИУ ВШЭ, ОП Экономика и
анализ данных'27
Серебряный призер
кейс-чемпионата
Pulse-Moex




Вероника Дмитренко
НИУ ВШЭ, ОП Экономика и
анализ данных'27
Победитель Cup Russia'24




Даниил Симонов
НИУ ВШЭ, ОП Экономика и
анализ данных'29
Победитель
кейс-чемпионата
от ППР & SBS Consulting



Илья Колосов
НИЯУ МИФИ, Прикладная
математика и информатика '27
Финалист Олимпиады
Я - профессионал по ИИ



Руслан Темерханов
НИУ ВШЭ, ОП Экономика и
анализ данных'28
Победитель Академии
Финтеха'25



ПРИЛОЖЕНИЕ

Ссылка на GitHub <https://github.com/svjskhntfrfk/mts-case/tree/main>

Ссылка на визуализацию <http://158.160.236.170:8080>
да, загрузка может занять немного больше времени, чем все привыкли в 21 веке

Case Crushers:

Арина Базукина

Вероника Дмитренко

Даниил Симонов


Илья Колосов

Руслан Темерханов




АНАЛИТИКА ДАТАСЕТОВ ОПРЕДЕЛИЛА РЕШЕНИЯ ПО СОСТАВУ И ПРЕДОБРАБОТКЕ ПРИЗНАКОВ

Заполненность полей Источника А




Заполненность полей Источника Б




- Большой объем пропусков вызван разделением зданий на мелкие полигоны
- Объединение геометрии объектов восстановит целостность данных

Площадь по категориям объектов




Общее распределение площади




- Значительный разброс значений площади требует логарифмирования признака для модели
- Площадь основания выступает базовой метрикой для оценки масштаба объекта

АНАЛИТИКА КАТЕГОРИАЛЬНЫХ ДАННЫХ ПОЗВОЛИЛА ОПРЕДЕЛИТЬ СТРАТЕГИЮ ОБРАБОТКИ ПРИЗНАКОВ ДЛЯ ОБУЧЕНИЯ МОДЕЛИ

Топ-15 типов объектов (Источник А)




Анализ параметров этажности (Источник А)



- Назначение объекта определяет базовый диапазон этажности
- Широкий разброс этажности построек и сооружений обусловил необходимость фильтрации выбросов

Топ-15 типов объектов (Источник Б)




Анализ параметров этажности (Источник Б)




- Базовая классификация скрывает существенный разброс этажности
- Приведение категорий к стандарту позволило учитывать тип здания в прогнозе

АНАЛИЗ МЕТРИЧЕСКИХ И ПРОСТРАНСТВЕННЫХ ДАННЫХ ВЫЯВИЛ СИЛЬНЫЕ ПРИЗНАКИ ДЛЯ ПРОГНОЗА

Пространственная автокорреляция высотности застройки



- Индекс Морана 0.63 доказывает значимую высотную кластеризацию застройки
- Средняя высота десяти ближайших объектов подтверждает сильную зависимость с корреляцией Пирсона 0.78
- Метрики соседних зданий компенсируют дефицит прямых признаков



- Средняя высота шести ближайших объектов выступает ключевым фактором прогноза с корреляцией 0.81
- Неравномерное распределение высотных кластеров требует опоры на соседние здания при предсказании высоты

ОТКУДА ВЗЯЛИСЬ ИДЕИ: ОБЗОР НАУЧНЫХ РАБОТ

Перед тем как придумывать признаки, мы изучили три научные работы, которые решали похожую задачу - предсказать высоту здания по его контуру, не используя спутниковые снимки. Ниже ключевые находки каждой работы.

Farella et al. 2021 - Реконструкция зданий по историческим картам

Авторы восстанавливали высоты зданий в итальянских городах Тренто и Болонья только по контурам на старых картах. Они сравнили **пять алгоритмов** и составили список из **16 признаков**, которые дают наилучший результат.

- Главный вывод: **назначение здания** (жилое / промышленное / церковь) оказалось важнее всех геометрических признаков вместе взятых.
- Алгоритм-победитель: **случайный лес**. Средняя ошибка - 1,1-2,3 м на зданиях, не изменивших форму.
- Важное открытие: церкви и башни составляют ~1% данных, но модель их полностью игнорирует без специальной **аугментации**. Для редких типов нужно искусственно увеличивать их долю в обучении.
- Пространственные признаки: плотность застройки на четырех радиусах (50/100/150/200 м) - каждый вносит независимый вклад.
- Валидация: **нельзя делать случайный split** - соседние здания "подсказывают" ответ через признаки окружения. Нужно **делить по географическим зонам**

Biljecki et al. 2017 - 3D-модели без данных о высоте (27 млн зданий Нидерландов)

Крупнейшее исследование на эту тему. Авторы обработали весь кадастр Нидерландов и проверили, как точность предсказания зависит от наличия/отсутствия данных об этажности.

- **Этажность** - сильнейший одиночный признак. Если она известна, ошибка падает до 1,2-1,8 м. Без нее - 2,5-3,8 м.
- **Случайный лес** снова лучший - стабильно обгоняет линейную регрессию, нейросети и метод опорных векторов.
- **Логарифм высоты** как целевая переменная улучшает результат: большинство зданий низкие, несколько высотных зданий не "тянут" модель вверх.

Liu et al. 2020 - IM2ELEVATION (глубокое обучение по снимкам)

Сверточная нейросеть, которая смотрит на снимок здания сверху и предсказывает высоту. Ошибка ~1,5 м - лучше всех. Но: нужны аэрофотоснимки, которых в нашем кейсе нет. Этот метод мы изучили, чтобы понять верхнюю границу точности, но применить не могли.

СРАВНЕНИЕ МОДЕЛЕЙ - РЕЗУЛЬТАТЫ ИЗ ЛИТЕРАТУРЫ

В рамках класса классических алгоритмов машинного обучения было протестировано пять подходов. Приведены их описания, численные результаты из опубликованных исследований.

Модель	RMSE (м)	MAE (м)	R²	Плюсы	Минусы
Linear Regression	5.6-8.5	4.4-6.8	−0.1-0.04	Интерпретируемость	Не улавливает нелинейность; слабо на сложных районах
Random Forest ★	3.6-4.7	2.8-3.6	0.49-0.57	Лучший баланс точность/скорость; важность признаков; устойчив к выбросам	Чуть хуже на экстремальных высотах (башни, шпили)
CatBoost	3.8-4.8	2.9-3.7	0.47-0.53	Нативная работа с категориальными признаками; хорошая точность	Немного уступает RF на данных с пространственными признаками
LightGBM	~3.5-4.5	~2.7-3.4	0.50-0.60	Быстрее CatBoost в 3-5x; хорошо масштабируется; DART для баланса	Менее стабилен без tuning на малых датасетах
SVR (RBF)	4.9-5.2	3.5-4.2	0.07-0.41	Хорошо при малом датасете	Медленный; плохо масштабируется на 160k+ записей
MLP (Neural Net)	4.2-4.9	3.2-3.8	0.36-0.48	Улавливает сложные зависимости	Требуется нормализации; переобучение без регуляризации
Ансамбль RF + CatBoost	~3.3-4.2	~2.6-3.3	0.55-0.65	Лучшее качество; усреднение снижает дисперсию	Сложнее интерпретировать; дольше обучение

СПРАВОЧНИК ПРИЗНАКОВ

Геометрические признаки 13 штук

Описывают форму и размер контура здания. Вычисляются один раз из геометрии полигона с помощью библиотеки Shapely

Переменная	Название	Как считается	Зачем нужен
area_m2	Площадь контура, м²	Из исходных данных	Основная мера размера здания
log_area	Логарифм площади	log(area + 1)	Выравнивает разброс от 10 до 100 000 м² — модели легче
perimeter_m	Периметр контура, м	Сумма длин рёбер полигона	Вместе с площадью показывает форму
log_perimeter	Логарифм периметра	log(perimeter + 1)	То же что log_area — нормирует диапазон
npi	Индекс компактности	2π×v(площадь) / периметр Круг=1; квадрат≈0.89; вытянутый→0	Г-, П-, Т-образные дома → промышленные, общественные
bbox_length	Длина описывающего прямоугольника, м	Длинная сторона минимального прямоугольника	Масштаб здания в длинном направлении
bbox_width	Ширина описывающего прямоугольника, м	Короткая сторона того же прямоугольника	Глубина здания
bbox_ratio	Вытянутость (длина / ширина)	bbox_length / bbox_width Башня ≈ 1-1.5; секционный ≈ 3-6	Башня vs длинный дом — разная типовая высота
bbox_fill_ratio	Заполненность прямоугольника	Площадь / (длина × ширина) Прямоугольник ≈ 0.95; Г-образное ≈ 0.5-0.7	Г-, П-образные советские дома имеют низкое значение
total_vertices	Число вершин контура	Сумма вершин по всем секциям Аппроксимация ≈ 5; детальный ≈ 50-200	Детальность геометрии; также критерий выбора источника
geom_parts	Число секций здания	Число отдельных полигонов в MultiPolygon	Многосекционные дома — крупные жилые комплексы
area_per_section	Средняя площадь секции, м²	area_m2 / geom_parts	Крупная секция → башня; много маленьких → ленточный дом
convexity	Выпуклость контура	Площадь / площадь выпуклой оболочки Выпуклое = 1.0; Г-образное ≈ 0.75	Вогнутые формы → советские административные, жилые

Пространственные признаки 17 штук

Характеристики окружения здания. Это самая сильная группа: средняя высота соседей в 100 м - самый важный признак в модели. Советские кварталы однородны: все 9-этажки вместе, все хрущевки вместе. Зная соседей, модель почти угадывает высоту. Вычисляются через kd-дерево (быстрый поиск ближайших соседей). Учитываются только здания с известной высотой

Переменная	Название	Как считается	Зачем нужен
centroid_x, centroid_y	Координаты центра здания (UTM)	Из геометрии	Городской тренд: центр СПб выше пригородов
dist_to_center	Расстояние до центра СПб, м	До Дворцовой площади по прямой	Этажность снижается от центра к окраинам
nearest_neighbor_dist	Расстояние до ближайшего соседа, м	Расстояние до центра 1-го соседа по kd-дереву	Малое → плотный квартал; большое → пригород, промзона. Топ-3 важнейших у Farella et al.
mean_height_100m	Средняя высота соседей 100 м	Среднее height всех соседей в 100 м (без самого здания)	★ СИЛЬНЕЙШИЙ признак. Соседи одинаковой высоты
median_height_100m	Медиана высоты соседей 100 м	Медиана height соседей в 100 м	Устойчивее к выбросам (один небоскрёб не искажает)
p75_height_100m	75-й процентиль высоты соседей	75-й процентиль height в 100 м	Верхняя планка квартала — для доминант застройки
std_height_100m	Разброс высот соседей 100 м	Стандартное отклонение height в 100 м	Однородный квартал (≈0) vs смешанная застройка
height_range_100m	Диапазон высот соседей (max – min)	max – min height в 100 м	Большой диапазон → разные эпохи застройки
count_neighbors_100m	Число соседей в 100 м	Число центроидов в 100 м	Плотность застройки
kde_50m / kde_100m / kde_150m / kde_200m	Плотность застройки (4 радиуса)	Число соседей / (π × r²) Единицы: зданий/м²	Каждый радиус вносит независимый вклад (Farella et al.): 50 м = квартал; 200 м = микрорайон
mean_height_by_distr_ict	Средняя высота по району СПб	Среднее height по всем зданиям района	Глобальный контекст: Петроградская ≠ Пушкин

Категориальные и атрибутивные признаки 17 штук

Назначение здания, этажность и метаданные из обоих источников. По Farella et al. назначение - самый важный одиночный признак: жилой дом, промышленный цех и церковь при одинаковой площади имеют кардинально разную высоту

Переменная	Название	Значения / расчёт	Зачем нужен
stairs_clean	Этажность здания (очищенная)	Этажность из источника Б, обрезанная до 1-100 (убираем «500 этажей» из ошибок нейросети)	Важнейший предиктор по Biljeski et al. Высота ≈ этажи × высота этажа
avg_floor_height	Средняя высота одного этажа, м	Из источника Б, 2-15 м Жилые: 2.5-3.3 м; пром.: 4-12 м	Нестандартно высокие потолки → промышленная функция
height_from_stairs	Расчётная высота по формуле	stairs × avg_floor_height	Базовая оценка; позволяет найти аномальные отклонения
height_stairs_diff	Разность фактической и расчётной высоты	height – height_from_stairs	Положительная → надстройки, шпилы; отрицательная → противоречие в данных
floor_mid_A	Средняя этажность из «Реформы ЖКХ»	(gkh_floor_min + gkh_floor_max) / 2 Заполнен у ~40% объектов	Косвенный признак для зданий без данных источника Б
floor_band_enc	Полоса этажности (код)	1→0; 2→1; 3-4→2; 5→3; 6-9→4; 10-16→5; 17-25→6; 26+→7	Дискретизация снижает чувствительность к ошибкам. Если в данных «16 вместо 17» — оба попадают в одну полосу
purpose_B_enc	Назначение из источника Б (код)	Жилое→0; Нежилое→1; Пром→2; Соц→3; Торг→4; Прочее→5	Важнейший категориальный признак (Farella et al.)
category_A_enc	Категория из источника А (код)	Жилое→0; Нежилое→1; Комплекс→2; Пром→3; Соц→4; Постройка→5	Дополняет purpose_B_enc для зданий только из источника А
is_residential	Флаг жилого здания (0/1)	1 если жилое хотя бы в одном источнике	Жилые дома → норматив 2.8-3.0 м/этаж; нежилые — нет
is_industrial_height	Флаг нестандартно высоких потолков	1 если avg_floor_height > 4 м	Промышленные здания — ~3% датасета, но критичны для планирования покрытия. Без флага модель их занижает
height_source_enc	Надёжность источника высоты (код)	Прямое→2; Расчётное→1; Нет→0	Метапризнак: используется как вес при обучении. Прямые измерения важнее
has_height	Флаг наличия известной высоты	1 если height_B известен, 0 иначе	Разделет обучающую выборку и выборку для предсказания
n_sources	Число источников данных (0/1/2)	(есть в А) + (есть в Б)	Здание в обоих источниках → значимый объект
iou_ab_clean	Степень совпадения геометрий А и Б (IoU)	Пересечение / Объединение полигонов Диапазон 0-1	Высокий IoU → сопоставление надёжно, данные о высоте достоверны
detail_ratio	Доля детальности источника А	вершин_A / (вершин_A + вершин_Б)	Источник с более детальной геометрией обычно точнее
floor_height_ratio	Нормировка высоты этажа	avg_floor_height / 3.0	Жильё ≈ 1.0; торговые ≈ 1.5-2.0; пром. ≈ 1.5-4.0
area_floor_product	Площадь × этажность	area_m2 × stairs_clean	Суррогат общей поэтажной площади. Крупные высотки → большое; гаражи → маленькое

В 10 ШАГОВ СОБРАЛИ УСТОЙЧИВЫЙ НАБОР ПРИЗНАКОВ ДЛЯ МОДЕЛИ

Шаг 1. Исследование данных (EDA)

Смотрели на пропуски, распределение высот, частоту категорий. Это позволило понять, какие поля надежны, а какие почти пустые.

Шаг 2. Конструирование признаков

Три группы: геометрия, пространство, категории. Всего ~45 признаков.

Шаг 3. Проверка на "квазиутечку"

Квазиутечка - это когда признак фактически является другой формулой той же целевой переменной. Например, $height_from_stairs = stairs \times avg_floor_height$ может совпадать с $height_B$, если avg_floor_height в источнике Б вычислен из той же высоты.
Критерий: $|корреляция\ с\ целевой\ переменной| > 0.95$ тогда признак исключается.
Корреляция 0.90–0.95 тогда проверка вручную.

Шаг 4. Устранение дублирующих признаков, коллинеарность

Если два признака слишком похожи друг на друга, взаимная корреляция > 0.95 , один из них лишний тк не добавляет информации, только шум.
Правило: из каждой такой пары оставляем тот признак, который легче объяснить (например, $stairs_clean$ важнее, чем $height_from_stairs$, если между ними высокая корреляция). Остается более интерпретируемый список.

Шаг 5. Удаление признаков с большими пропусками

Если в признаке более 80% значений пустые - он бесполезен. Такие признаки удаляются сразу. Для признаков с умеренными пропусками (5-80%): пустые значения заменяются медианой + добавляется бинарный флаг $_was_nan\ 1 =$ было пусто. Медиана считается только по обучающей части.

Шаг 1. Исследование данных (EDA)

Смотрели на пропуски, распределение высот, частоту категорий. Это позволило понять, какие поля надежны, а какие почти пустые.

Шаг 2. Конструирование признаков

Три группы: геометрия, пространство, категории. Всего ~45 признаков.

Шаг 3. Проверка на "квазиутечку"

Квазиутечка - это когда признак фактически является другой формулой той же целевой переменной. Например, $height_from_stairs = stairs \times avg_floor_height$ может совпадать с $height_B$, если avg_floor_height в источнике Б вычислен из той же высоты.
Критерий: $|корреляция\ с\ целевой\ переменной| > 0.95$ тогда признак исключается. Корреляция 0.90–0.95 тогда проверка вручную.

Шаг 4. Устранение дублирующих признаков, коллинеарность

Если два признака слишком похожи друг на друга, взаимная корреляция > 0.95 , один из них лишний тк не добавляет информации, только шум.
Правило: из каждой такой пары оставляем тот признак, который легче объяснить (например, $stairs_clean$ важнее, чем $height_from_stairs$, если между ними высокая корреляция). Остается более интерпретируемый список.

Шаг 5. Удаление признаков с большими пропусками

Если в признаке более 80% значений пустые - он бесполезен. Такие признаки удаляются сразу. Для признаков с умеренными пропусками (5-80%): пустые значения заменяются медианой + добавляется бинарный флаг $_was_nan\ 1 =$ было пусто. Медиана считается только по обучающей части.

ЧТО ОТСЕИВАЛОСЬ И ПОЧЕМУ? ИЗ 47 КАНДИДАТОВ В ФИНАЛЬНЫЙ СПИСОК ДЛЯ ОБУЧЕНИЯ ВОШЛИ 35

Этап отбора

Что отсеивалось	На каком шаге	Причина
height_from_stairs (в первоначальном виде)	Диагностика квазиутечки	Корреляция с целевой переменной > 0.95. Фактически это другая запись той же высоты через avg_floor_height. Оставлен как вспомогательный признак с отдельным флагом
log_perimeter (в одном из вариантов)	Коллинеарность	Высокая корреляция с log_area (оба описывают «размер»). Оставили log_area как более интерпретируемый
Признаки с > 80% пропусков	Фильтр пропусков	Бесполезны: слишком мало данных, чтобы модель могла научиться. Конкретный список зависит от данных, но обычно это редкие атрибуты из источника А
Признаки с низкой важностью (хвост рейтинга)	Bootstrap-CI выбор К	После К=35 добавление новых признаков не даёт статистически значимого улучшения MAE (CI нового К не выходит за CI baseline)
Расстояния на радиусах > 200 м	Анализ важности	Признаки kde_250m, kde_300m практически не добавляли информации поверх kde_200m — в итоговый список не вошли

Итоговые признаки

Группа	Признаки
Геометрические (10)	area_m2, log_area, perimeter_m, npi, bbox_length, bbox_width, bbox_ratio, bbox_fill_ratio, total_vertices, geom_parts
Пространственные (15)	centroid_x, centroid_y, dist_to_center, nearest_neighbor_dist, mean_height_100m, median_height_100m, p75_height_100m, std_height_100m, height_range_100m, count_neighbors_100m, kde_50m, kde_100m, kde_150m, kde_200m, mean_height_by_district
Категориальные (10)	stairs_clean, avg_floor_height, floor_band_enc, purpose_B_enc, category_A_enc, is_residential, is_industrial_height, n_sources, iou_ab_clean, floor_height_ratio

ТАК ЖЕ ИЗ ИССЛЕДОВАНИЙ БЫЛИ ВЗЯТЫ ОСНОВНЫЕ ПОДХОДЫ К ОЦЕНКЕ МОДЕЛИ И ПРЕОБРАЗОВАНИЕ ТАРГЕТА

Модель предсказывает логарифм высоты: $\log(\text{высота} + 1)$. На этапе получения результата делаем обратное преобразование: $\exp(\text{предсказание}) - 1$.

- Почему так?
- Высоты зданий в СПб распределены очень неравномерно: большинство домов 9-30 м, но есть одноэтажные сараи (3-4 м) и высотки (75-150 м).
 - Если предсказывать метры напрямую, модель при обучении сильно штрафует за ошибки на высотных зданиях и почти игнорирует ошибки на малоэтажных.
 - Логарифм выравнивает распределение. Ошибка в 3 м на одноэтажке (4 м) воспринимается так же важно, как ошибка в 3 м на девятиэтажке (27 м).

Переменная	Описание
target_height	Фактическая высота, м — медиана по полигонам Источника Б. Медиана, а не одно значение, т.к. здание может быть представлено несколькими полигонами
log_target_height	$\log(\text{target_height} + 1)$ — то, что предсказывает модель. Обратное: $\exp(\text{pred}) - 1$ = высота в метрах

Используемые метрики качества и их смысл

Метрика	Что измеряет	Целевое значение	Обоснование
MAE (средняя абсолютная ошибка, м)	Среднее отклонение предсказания от факта по всем зданиям	< 3 м	Ошибка 3 м $\approx$ один этаж. Farella et al.: цель 2 м. Biljecki et al.: 1.2 м при наличии этажности
RMSE (среднеквадратичная ошибка, м)	То же, но большие ошибки штрафуются сильнее. Чувствителен к выбросам	< 5 м	Штрафует за грубые ошибки на высотных зданиях и башнях — критично для расчёта «мёртвых зон»
R ² (коэффициент детерминации)	Доля разброса высот, которую модель объяснила. R ² =1 — идеально, R ² =0 — как среднее	> 0.5	Выше 0.5 означает, что модель лучше простого «средняя высота по городу». На однородных кварталах R ² > 0.9
Асс2м (точность ± 2 м)	Доля зданий, у которых ошибка не превышает 2 м	> 50%	Прагматичная метрика: каждое второе здание с ошибкой не более одного этажа
Асс3м (точность ± 3 м)	Доля зданий с ошибкой ≤ 3 м	> 65%	Дополняет Асс2м для оценки общей достаточности модели

ОБУЧЕНИЕ МОДЕЛИ RANDOM FOREST

Параметры модели были взяты исходя из научной статьи (Farella et al. 2021)

Параметр	Значение	Зачем
n_estimators	400	Число деревьев. 400 — компромисс качества и скорости
max_features	sqrt (~6 из 35)	Каждый узел видит случайное подмножество признаков — снижает корреляцию деревьев
min_samples_leaf	5	Минимум 5 объектов в листе. Рекомендация Farella et al. 2021
max_depth	None	Деревья растут до конца; min_samples_leaf не даёт переобучиться
oob_score	True	Out-of-Bag оценка: каждый объект проверяется деревьями, что его не видели

Пространственная кросс-валидация

Метод: KMeans по координатам делит город на 5 зон. Каждая зона поочередно становится тестовой, остальные 4 обучающими. Тестовая зона территориально отделена от обучающих.

Зачем: обычное случайное разбиение завышает метрики - соседние здания похожи и «подсказывают» ответ (пространственная автокорреляция). Spatial CV исключает этот эффект.

Результат: 5 значений MAE/RMSE/R2. Среднее - честная оценка модели. Разброс между зонами показывает стабильность по городу.

Аугментация редких высоких зданий

Проблема: здания выше 50 м - менее 5% данных, но критичны для расчета зон покрытия сотовых станций. Без специальных мер модель систематически занижает их высоту.

Решение (по Farella et al. 2021): каждое здание выше 50 м копируется 3 раза. В копии геометрические признаки получают случайный шум $\pm 10\%$, высота остается точной такой же, как у оригинала.

ОБУЧЕНИЕ МОДЕЛИ CATBOOST

Параметры модели

Кросс-валидация по районам (GroupKFold)

Метод: каждый административный район Санкт-Петербурга - отдельная группа. При разбиении на 5 частей ни одно зданиеиз одного района не попадает одновременно в о бучение и проверку.

Запасной вариант (если данных о районе нет): пространственная сетка 150 0×1500 м - здания в одной ячейке считаются одной группой.

Ранняя остановка в каждом фолде. После CV: финальное число итераций = медиана лучших итераций по всем фолдам.Финальная модель обучается на всех данных.

Параметр	Значение	Зачем
loss_function	RMSE	Среднеквадратичная ошибка — цель обучения
iterations	2000	Максимум деревьев. Реально строится меньше — ранняя остановка
learning_rate	0.03	Малый шаг: каждое дерево вносит небольшой вклад. Меньше переобучения
depth	8	Глубина дерева — улавливает сложные взаимодействия признаков
l2_leaf_reg	5.0	L2-регуляризация: штрафует за слишком большие предсказания в листьях
early_stopping_rounds	150	Если за 150 шагов нет улучшения на проверочных данных — остановка
use_best_model	True	Возвращается модель с лучшей итерацией, а не последняя

РАЗБИЛИ ГОРОДСКУЮ ЗАСТРОЙКУ НА 11 ТИПОВ СРЕДЫ С РАЗНОЙ ЛОГИКОЙ ПЛАНИРОВАНИЯ

Как делали

- 1

Описали каждое здание и его окружение

высота, площадь, форма, тип здания и характеристики среды вокруг
- 2

Подготовили признаки для кластеризации

убрали перекосы, заполнили пропуски, нормализовали данные
- 3

Сжали пространство признаков через PCA

сохранили основную информацию и ускорили кластеризацию
- 4

Подобрали оптимальное число кластеров

сравнили несколько вариантов и выбрали лучший по метрикам качества
- 5

Разбили здания на кластеры и интерпретировали результат

для каждого кластера собрали профиль и связали его со стратегией радиопланирования

В результате получили 11 кластеров городской среды

Высотные жилые башни
14-17+ эт., высота >40 м,
малый периметр
Capacity - приоритет

Исторический центр
3-7 эт., плотность застройки
>0.28
Capacity + indoor

Советские плиты и спальные районы
5-12 эт., однородная среда
Coverage + Capacity

Малоэтажная периферия
1-3 эт., ИЖС, гаражи,
пригороды
Coverage, 800 МГц

Промышл. зоны и склады
Промышл. окружение
Coverage, низкий приоритет

Смешанная застройка
Переходные зоны, высокая
энтропия типов
Индив. анализ

Каждому кластеру автоматически присвоена стратегия базовой станции (Capacity/Coverage/Mixed) для использования в радиопланировщиках
Coverage - задача покрыть территорию сигналом
Capacity - задача «вместить» много пользователей и трафика
Mixed (Coverage + Capacity) - баланс двух задач
Indoor - покрытие внутри зданий

Переход к адресному планированию сети дает практический результат

Типовые сценарии радиопланирования

Приоритизация районов под развитие сети:

Различение coverage-driven и capacity-driven зон:

Повышение точности размещения базовых станций

За КАЖДЫМ КЛАСТЕРОМ СТОИТ НЕ ЯРЛЫК, А УСТОЙЧИВЫЙ ПРОФИЛЬ ГОРОДСКОЙ СРЕДЫ

Кластер 1: Малоэтажная периферия (ИЖС, гаражи) - А

Рассредоточенная малоэтажная застройка с самой низкой плотностью в выборке (0.04). Мелкие объекты (~59 м²) - частные дома, гаражи, хозяйственные постройки. Окружение на 93% жилое, 72 соседа в радиусе 200 м, но суммарная площадь застройки минимальна. Нулевой разброс высот (std=0, CoV=0) - полностью однородная среда. Высокая доля коммерческого тега (1.0) объясняется кодировкой is_other.

Зданий	Доля	Высота	Этажей	Плотность	Площадь
2 809	3.3%	6.6 м	2	0.04	59 м²

Кластер 2: Исторический центр (плотная среда)

Крупнейший жилой кластер и самая плотная застройка (d=0.32) - вчетверо выше среднего по городу. Типичная дворовая среда исторического центра: 3-этажные здания с площадью 486 м², 53 соседа в 200 м. Энтропия типов 0.59 - высокая функциональная смешанность (жилое 85%, коммерческое 11%). Средняя высота контекста 12.1 м, умеренный разброс(std=4.75). Плотная квартальная сетка и дворы-колодцы критически ограничивают распространение радиосигнала.

Зданий	Доля	Высота	Этажей	Плотность	Площадь
16 338	18.9%	9.9 м	3	0.32	486 м²

Кластер 3: Высотные жилые башни (17+ эт.)

Современные высотные жилые комплексы - самые высокие здания в выборке (медиана 51 м, 17 этажей). Компактноеоснование (129 м²), умеренная плотность. Окружение на 90% жилое. Ключеваяособенность - средняя высота соседей 35.8 м(тоже высотки) с максимальным разбросом (std=19.1): башни стоят рядом с существенно более низкой застройкой. Коэффициент вариации высот 0.54 - значительная высотная неоднородность зоны.

Зданий	Доля	Высота	Этажей	Плотность	Площадь
5 849	6.8%	51.0 м	17	0.13	129 м²

Кластер 4: Малоэтажная периферия (ИЖС, гаражи) - Б

Карликовый кластер (0.2% - возможный артефакт K-Means). Крупные одноэтажные объекты (1 783 м²) при жилом окружении (93%). Всего 18 соседей в 200 м - изолированные крупные постройки. Вероятно: крупные ИЖСучастки схозяйственными строениями, крытые спортивные объекты или торговые точки в жилых районах. Промышленная доля 12% - выше, чем у обычного жилого. Требует визуальной проверки на карте.

Зданий	Доля	Высота	Этажей	Плотность	Площадь
207	0.2%	4.5 м	1	0.14	1 783 м²

Кластер 5: Малоэтажная периферия (ИЖС, гаражи) - В

Второй по размеру кластер - массовая малоэтажная периферия города. Одноэтажные постройки площадью 145 м², низкая плотность (0.07). Окружение на 98% жилое - минимальная энтропия типов (0.11), самая функционально однородная среда в городе. 33 соседа в 200 м. Это пригороды, садоводства, гаражные кооперативы, частный сектор. Отличается от кластера 0 более низкой плотностью и отсутствием коммерческой примеси

Зданий	Доля	Высота	Этажей	Плотность	Площадь
14 807	17.1%	4.5 м	1	0.07	145 м²

За КАЖДЫМ КЛАСТЕРОМ СТОИТ НЕ ЯРЛЫК, А УСТОЙЧИВЫЙ ПРОФИЛЬ ГОРОДСКОЙ СРЕДЫ

Кластер 6: Склады и производственные территории

Крупнейший кластер в абсолютных числах – промышленные и складские зоны. Одноэтажные объекты средней площади (478 м²) при высокой плотности (0.20). Окружение на 86% промышленное, жилая доля лишь 35% (is_residential=0 для медианного здания). Средняя высота контекста 8.0 м с разбросом 4.54 – невысокие производственные корпуса. 4 934 жилых здания в этом кластере получили индивидуальные перебитые метки.

Кластер 7: Крупные советские дома (6–9 эт., большой корпус)

Крупнопанельные жилые дома с протяженными корпусами (медиана 1 790 м² – второй показатель после кластера 7). 6этажей, умеренная плотность. Контекст высотно неоднородный (std=10.6, CoV=0.56) – рядом стоят и более высокие, и более низкие здания. Типичны для советских микрорайонов 1960–80-х. Окружение на 82% жилое, энтропия 0.49 – умеренная функциональная смешанность.

Кластер 8: Крупные жилые плиты (9+ эт.)

Карликовый, но содержательно важный кластер – самые крупные жилые корпуса в городе (2 317 м²). Девятиэтажные панельные дома с длинными секциями. Низкая плотность (0.12) – стоят обособленно в микрорайонах. Средняя высота окружения 20.4 м, высокий разброс (std=12.0, CoV=0.56) – переходная зона между средне- и высотной застройкой. Окружение на 78% жилое, энтропия 0.40.

Кластер 9: Хрущевки и типовые спальные районы

Среднеэтажная застройка спальных районов: 3 этажа, площадь 668 м², плотность 0.17. Ключевая особенность – максимальная энтропия типов в выборке (0.70): это наиболее функционально смешанная среда в городе. Долякоммерческого окружения 19% – рядом торговые центры, офисы, учреждения. Медианное здание нежилого типа (is_residential=0), что подтверждает смешанный характер. Средняя высота контекста 13.4 м – перемешанность с болеевысокой застройкой.

Кластер 10: Сталинская и послевоенная застройка

Третий по размеру кластер – шестиэтажные жилые здания с компактным основанием (192 м²). Умеренная плотность,окружение на 85% жилое. Ключевая характеристика – самая высокая средняя высота контекста среди среднеэтажных кластеров (23.2 м) и максимальный разброс (std=13.9, CoV=0.61): сталинские дома часто соседствуют с более высокимидомами поздних серий. Энтропия типов 0.42 – преимущественно жилая функция.

Кластер 11: Крупные советские дома (4–5 эт., большой корпус)

Пятиэтажные здания с крупными корпусами (1 210 м²) – типичные хрущевки и брежневки с длинными секциями. Плотность ниже среднего (0.13), окружение на 84% жилое. Средняя высота контекста 14.7 м, умеренный разброс (std=8.2). Энтропия 0.50 – функционально однородные спальные районы. Близок к кластеру 6, но ниже на 1–2 этажа и с меньшей площадью основания.

Зданий	Доля	Высота	Этажей	Плотность	Площадь
15 402	17.8%	4.5 м	1	0.20	478 м²

Зданий	Доля	Высота	Этажей	Плотность	Площадь
4 671	5.4%	20.0 м	6	0.14	1 790 м²

Зданий	Доля	Высота	Этажей	Плотность	Площадь
989	1.1%	27.0 м	9	0.12	2 317 м²

Зданий	Доля	Высота	Этажей	Плотность	Площадь
7 217	8.4%	9.9 м	3	0.17	668 м²

Зданий	Доля	Высота	Этажей	Плотность	Площадь
12 367	14.3%	18.0 м	6	0.14	192 м²

Зданий	Доля	Высота	Этажей	Плотность	Площадь
5 719	6.6%	15.0 м	5	0.13	1 210 м²

ТИПЫ ГОРОДСКОЙ СРЕДЫ СВОДЯТСЯ К 4 БАЗОВЫМ СЦЕНАРИЯМ РАЗВИТИЯ СЕТИ

Capacity

Задача: вместить много пользователей и трафика.
Приоритет - пропускная способность, не дальность.
Инструменты: высокие частоты (1800–2600 МГц), малые соты, плотная сеть станций.
Где: высотки, исторический центр.

Coverage

Задача: покрыть территорию сигналом.
Приоритет - дальность, не скорость.
Инструменты: низкие частоты (800–900 МГц), мощные широкие соты.
Где: периферия, промзоны, пригороды

Coverage + Capacity

Баланс двух задач.
Нужно и покрыть, и выдержать нагрузку.
Типично для спальных районов: плотность абонентов средняя, площадь больша

Indoor

Покрытие внутри зданий.
Нужно там, где сигнал снаружи не проходит через толстые стены плотной застройки.
Решения: DAS, small cells в подъездах, дворах

Тип застройки	Признаки кластера	Стратегия БС	Радио-зона	Приоритет
Высотные жилые башни (17+ эт.)	>50 м, 17+ эт., малый периметр	Capacity	Capacity + многоуровневые антенны (приоритет)	★★★ Высокий
Высотные жилые башни (14–16 эт.)	40–50 м, 14–16 эт.	Capacity	Capacity + антенны на уровне крыш	★★★ Высокий
Крупные жилые плиты (9+ эт.)	25–40 м, 9+ эт., площадь >800 м²	Capacity	Capacity-driven, жилой трафик	★★★ Высокий
Исторический центр (плотная среда)	3–7 эт., плотность >0.28	Capacity + Indoor	Capacity-driven, высокий приоритет, indoor	★★★ Высокий
Сталинская и послевоенная застройка	5–7 эт., ср. плотность (0.12–0.20)	Coverage + Capacity	Coverage + Capacity, смешанный трафик	★★★ Средний
Крупные советские дома (6–9 эт., большой корпус)	6–9 эт., площадь >900 м², плотность >0.12	Coverage + Capacity	Coverage + Capacity, стандарт	★★★ Средний
Хрущёвки и типовые спальные районы	4–5 эт., плотность >0.14	Coverage + Capacity	Coverage + Capacity, стандарт	★★★ Средний
Малоэтажная городская застройка	2–3 эт., средняя плотность	Coverage	Coverage-driven, средний приоритет	★★★ Низкий
Малоэтажная периферия (ИЖС, гаражи)	1–2 эт., ИЖС, гаражи, пригороды	Coverage	Coverage-driven, низкий приоритет	★★★ Низкий
Промышленная застройка (средне- и высотная)	>15 м, промышл. окружение >35%	Coverage	Coverage-driven, рабочий трафик	★★★ Низкий
Склады и производственные территории	<15 м, большая площадь, промышл. окружение	Coverage	Coverage-driven, низкая нагрузка	★★★ Низкий
Смешанная промышленно-жилая зона	Промышл. доля 20–35%, нет чёткого типа	Coverage + Capacity	Coverage + Capacity, неоднородный трафик	★★★ Средний

ТИП ГОРОДСКОЙ СРЕДЫ ПОМОГАЕТ ЗАРАНЕЕ ВЫБРАТЬ ПРАВИЛЬНЫЙ СЦЕНАРИЙ РАЗВИТИЯ СЕТИ

1. Высотные зоны – критика вертикального планирования 5 849 зданий (6.8%) с медианной высотой 51 м формируют «вертикальный город». При средней высоте окружения 35.8 м и разбросе 19.1 м наземные базовые станции не способны обеспечить покрытие верхних этажей – здания создают радиотень. Рекомендация: многоуровневые антенны с нижним тилтом для 1–8 этажей и верхним для 9–17+. Компактные основания (129 м²) позволяют размещать малые соты на фасадах без значительных затрат на инфраструктуру.	
2. Исторический центр – приоритет indoor-покрытия 18.9% зданий (16 338) при плотности d=0.32 – самый плотный кластер. Замкнутые дворы-колодцы экранируют радиосигнална каждом шаге. Энтропия типов 0.59 означает смесь жилого и коммерческого, то есть трафик и жилой (вечер), и рабочий/покупательский (день). Рекомендация: DAS (Distributed Antenna System) в подъездах, small cells на уровне 2–3 этажа, пилотные indoor-решения для торговых точек первых этажей. Это наиболее капиталоемкий, но и наиболее экономическиоправданный сегмент – высокая плотность населения и коммерции.	
3. Периферия – оптимизация CAPEX Кластеры 0 и 4 суммарно: 17 616 зданий (20.4%) с плотностью 0.04–0.07. Это значительная доля территории с минимальным трафиком: ИЖС, гаражи, садоводства. Размещать частые соты экономически нецелесообразно. Рекомендация: широкие соты в диапазонах 800/900 МГц с радиусом покрытия 2–5 км. Это может обеспечить экономию CAPEX до 40% по сравнению с равномерным размещением БС.	
4. Промышленные зоны – разделение ресурсов 15 402 здания (17.8%) – склады и производства с нагрузочным профилем «рабочий день» (пн-пт, 8–18). Ночью и в выходные нагрузка минимальна. 4 934 жилых здания, попавших в промышленный кластер и получивших перебитые метки, подтверждают пограничность зон: промышленные территории граничат с жилыми районами. Рекомендация: динамическое перераспределение ресурсов – днем приоритет промзоне, вечером – соседним жилым кластерам. Совместная инфраструктура вместо дублирования.	
5. Советские микрорайоны – базовый сегмент Кластеры 6, 7, 9, 10 суммарно: 23 746 зданий (27.5%) – основной жилой фонд города. Крупнопанельные дома 5–9 этажей с площадью корпуса 192–2 317 м². Высотная неоднородность (CoV 0.53–0.61) означает чередование 5-этажек с 9-этажками в одном микрорайоне. Рекомендация: стандартные макросоты с антенной на уровне крыш 9-этажных домов (27 м). Это обеспечивает покрытие и более низких зданий, и верхних этажей 9-этажек.	
6. Зоны функциональной смешанности Кластер 8 (7 217 зданий, 8.4%) имеет максимальную энтропию типов (0.70) – наиболее функционально смешанная среда.19% коммерческого окружения: торговые центры, офисы, учреждения обслуживания. Трафик наиболее непредсказуем: дневные пики от работников/покупателей + вечерние от жителей. Рекомендация: гибкое управление емкостью – Carrier Aggregation, динамическая балансировка нагрузки, возможно MIMO для повышения пропускной способности в пиковые часы.	